

南方科技大学校园知识库 RAG 项目

工程实施交接手册

系统设计、数据工程、检索、部署、评测与答辩全流程

项目项	确定方案
项目类型	Project 1: SUSTech Campus Knowledge Base Construction with RAG
系统定位	面向南科大学学生与申请者的可溯源校园知识问答系统
核心检索	Dense + BM25 + RRF + Cross-Encoder Reranker
生成服务	本地 Qwen 8B 级模型 + vLLM OpenAI-compatible API
检索后端	Qdrant; FAISS 仅作为基础实验或故障降级
前后端	FastAPI + Gradio
目标数据量	200-300 个有效网页、20-40 份官方 PDF、约 5,000-12,000 chunks
目标硬件	RTX 4090D 24GB、16 vCPU、80GB RAM
文档用途	交给接手者可从空服务器按步骤完成系统、实验与展示

版本: v1.0 / 日期: 2026-06-11

快速导航

需求	建议直接阅读
第一次理解项目	第 1-4 章：范围、架构、硬件、技术决策
准备抓取数据	第 5-9 章：来源注册、爬虫、网页/PDF、数据模型与版本
准备建索引	第 10-13 章：Chunk、Embedding、Qdrant、BM25 与混合检索
准备部署模型	第 14-18 章：在线流程、LLM、Prompt、API 与前端
准备跑实验	第 19-22 章：评测集、实验矩阵、指标和错误分析
准备交付和答辩	第 23-27 章：测试、日志、里程碑、演示与交付
出现故障	第 26 章：风险、降级与排查

文档使用约定

- 本文给出的是默认推荐实现。任何替换都必须记录原因、版本、效果和资源代价。
- 先跑通最小闭环，再逐步加 BM25、RRF、Reranker、查询拆分；禁止一开始堆满所有模块。
- 数据、索引、模型和评测结果都必须可追溯到版本号与构建配置。
- 现场展示不得依赖外网或云模型；云模型只能作为可选评测上界。
- 旧政策不删除，但必须标明 effective_year、status 和来源权威等级。

目录（章节导航）

1. 项目目标、边界与交付标准
2. 总体架构与端到端数据流
3. 服务器资源与部署拓扑
4. 技术选型与替代方案
5. 数据源范围与采集规模
6. 数据源注册表与 URL 发现
7. 网页采集、解析与清洗
8. PDF 与培养方案解析
9. 统一数据模型、去重与版本管理
10. Chunking 与 Parent-Child 设计
11. Embedding 与离线向量化
12. Qdrant、BM25 与索引一致性
13. 混合检索、RRF 与 Reranker
14. Query 分析、多轮改写与比较题拆分
15. 上下文组装、证据充分性与拒答
16. 本地生成模型与 vLLM 部署

- 17. Prompt、引用映射与输出协议
- 18. FastAPI、Gradio 与服务接口
- 19. 评测集构建与标注规范
- 20. 实验矩阵、公平比较与参数选择
- 21. 指标、人工评测与 LLM Judge
- 22. 错误分析与调试路径
- 23. 日志、监控、测试与复现
- 24. 从零实施步骤与命令顺序
- 25. 里程碑、验收标准与时间计划
- 26. 风险、降级与故障排查
- 27. 答辩演示与最终交付清单
- 附录 A. 官方数据源种子清单
- 附录 B. 配置模板与数据 Schema
- 附录 C. 参考资料

1. 项目目标、边界与交付标准

1.1 最终系统定义

本项目最终交付一个“南方科技大学校园知识助手”。系统从南科大官方公开网页和 PDF 构建本地知识库，能够对专业培养、教学制度、招生、学生事务、图书馆、书院、研究生与国际交流等问题给出基于证据的回答，并展示真实来源、适用年份与原文片段。

1.2 面向用户与核心问题

- 在校本科生：培养方案、进专业、课程、学分、办事流程、校园服务。
- 研究生：培养与学位、奖助、迎新、研究生院办事信息。
- 申请者：招生政策、专业与学院、培养特色、国际交流。
- 教师或答辩评审：可查看系统检索证据、数据规模、实验指标与错误分析。

1.3 必须完成、推荐增强与明确不做

层级	内容
必须完成	公开数据采集；清洗与切分；向量化；本地 LLM；RAG 闭环；来源引用；No-RAG 对比；评测与演示。
推荐增强	BM25；RRF；Reranker；结构感知切分；年份过滤；比较题拆分；证据调试页面。
不纳入首版	知识图谱；Agent 自主规划；模型微调；实时全网搜索；用户权限系统；大规模分布式服务。

1.4 交付验收口径

1. 离线可从 source registry 重新抓取并重建知识库；每个 chunk 能追溯到原始 URL/PDF 页码。
2. 在线可在无外网环境中提问；系统返回答案、引用、证据片段和适用年份。
3. 至少完成 No-RAG、Dense、Hybrid、Hybrid+Reranker 四组对比。
4. 固定测试集不少于 60 题，包含事实题、代码题、比较题、时效题和无答案题。
5. 现场演示时可以切换检索模式并查看检索结果；发生模型故障时有降级方案。

2. 总体架构与端到端数据流

2.1 离线知识库构建

Source Registry

- > URL Discovery / PDF Discovery
- > Raw Archive + Manifest
- > HTML/PDF Parsing
- > Normalization + Deduplication
- > Structure-aware Chunking
- > Metadata Enrichment
- > Embedding + Dense Index

- > BM25 Index
- > Index Manifest / Version Freeze

离线链路必须可重复执行，且每一步输出独立中间产物。不要写成一个无法断点恢复的“大脚本”。

2.2 在线问答

User Query + Recent Conversation

- > Query Analyzer
- > Standalone Query / Sub-queries / Filters
- > Dense Search || BM25 Search
- > RRF Fusion
- > Cross-Encoder Rerank
- > Deduplicate + Version Resolution + Parent Expansion
- > Context Budgeting
- > vLLM Generation
- > Citation Validation
- > Answer + Source Cards + Trace

2.3 模块职责边界

模块	输入	输出	禁止承担
Crawler	source registry	raw files + manifest	不负责正文清洗
Parser	raw HTML/PDF	normalized document	不生成 embedding
Chunker	normalized document	chunks + hierarchy	不决定检索分数
Indexer	chunks	Qdrant/BM25 索引	不生成回答
Retriever	query + filters	候选 chunks	不修改原始文档
Generator	evidence + user query	带引用答案	不创造 URL 或资料
Evaluator	frozen config + test set	metrics + cases	不边评测边调参

3. 服务器资源与部署拓扑

3.1 资源预算

资源	配置/用途	实施要求
GPU	RTX 4090D 24GB	生成模型常驻；离线 Embedding 独占；Reranker 视显存放 GPU 或 CPU。
CPU	16 vCPU	爬虫、PDF 解析、BM25、Qdrant、FastAPI、Gradio。
RAM	80GB	足够保存索引与缓存；避免全量 PDF 图像常驻。
磁盘	约 50GB 可用	严格控制模型缓存，不在 Docker image 复制权重。
CUDA	以服务器实测为准	先核对 driver、torch、vLLM 兼容，再锁定 requirements。

3.2 推荐拓扑

```
Host OS / GPU
- vLLM server (port 8000)
- Model weights and HF cache

Docker Compose
- qdrant (6333/6334)
- rag-backend FastAPI (8080)
- gradio frontend (7860)

Host/Container shared volumes
- /srv/sustech-rag/data
- /srv/sustech-rag/qdrant_storage
- /srv/sustech-rag/logs
```

3.3 建议目录

```
/srv/sustech-rag/
models/
  generator/
  embedding/
  reranker/
data/
  raw/html raw/pdf
  parsed normalized chunks eval manifests
qdrant_storage/
indexes/bm25/
logs/
cache/
project/
```

4. 技术选型与替代方案

4.1 固定技术栈

层	默认选择	原因	降级/替代
网页采集	httpx/requests + BeautifulSoup + trafilatura	可控、易调试	Scrapy; 站点定制解析
PDF	PyMuPDF + Docling (复杂版式)	文本快、表格可增强	pdfplumber; 必要时 OCR
Chunk	自定义结构感知切分	能保留条款、表格和层级	固定长度 baseline
Embedding	Qwen3-Embedding-0.6B	中文、体量适中	BGE-M3
向量库	Qdrant	payload/filter/持久化/混合查询	FAISS
稀疏检索	BM25	解释清晰、课程代码强	Qdrant sparse
融合	RRF	不依赖分数归一化	加权融合
Reranker	Qwen3-Reranker-0.6B	与 embedding 体系一致	bge-reranker-v2-m3
生成	Qwen 8B 级量化模型	中文、单卡可部署	更小模型
Serving	vLLM	OpenAI-compatible、流式	Transformers 临时服务
后端/前端	FastAPI + Gradio	服务化、演示快	Streamlit

5. 数据源范围与采集规模

5.1 数据边界

数据以南方科技大学官方域名和公开镜像为主。核心范围包括学校概况、教学规章、专业培养、招生、学生事务、书院、图书馆、研究生、国际交流、信息服务、校园健康。默认排除大规模新闻、教师个人成果、招聘、会议、名单和重复宣传页。

5.2 目标规模

类别	目标数量	备注
学校与院系稳定页面	40-60	学校概况、院系、专业、组织机构
本科教学/制度	30-60	培养方案、学籍、选课、学位、校历
招生	20-35	简章、培养特色、FAQ，保留年份
学生事务与书院	35-60	办事、奖助、心理、交通、打印、书院
图书馆与校园服务	25-40	开馆、借阅、预约、校外访问
研究生与国际交流	25-40	培养、奖助、交换、短期项目
官方 PDF	20-40	培养方案、学生手册、制度、指南
总计	约 200-300 网页 + 20-40 PDF	预计 5,000-12,000 chunks

5.3 采集优先级

- P0：最新培养方案、教学制度、招生简章、学生事务 FAQ、图书馆服务。
- P1：学院/专业介绍、书院、研究生培养、国际交流。
- P2：少量近期通知，用于验证时效性；必须标记 `published_date` 和 `status`。
- P3：历史材料，仅用于指定年份查询，不作为默认当前答案。

6. 数据源注册表与 URL 发现

6.1 Source Registry

```

source_id: tao_undergrad
name: 本科教学相关公开信息
base_url: https://tao.sustech.edu.cn/
allowed_domains: [tao.sustech.edu.cn, mirrors.sustech.edu.cn]
allowed_paths: [/]
excluded_patterns: [/search, /tag, /print, /faculty, /news/old]
category: undergraduate_teaching
authority_level: 100
crawl_depth: 3
max_pages: 80
update_frequency: monthly
enabled: true

```

6.2 URL 发现顺序

6. 读取人工维护的 seed URL；先建立最小清单而非直接全站爬取。
7. 抓取 sitemap.xml（若存在），但仍应用 allow/exclude 规则。
8. 解析站内链接，限制域名、深度、路径和 MIME 类型。
9. 发现 PDF 时写入单独队列，下载前执行文件名、大小、年份和哈希检查。
10. 搜索引擎仅用于补充遗漏入口；最终入库必须回到官方域名验证。

6.3 URL 规范化

- 去除 fragment；清理 tracking query；统一 trailing slash；解析相对 URL。
- 识别 print/mobile/amp 重复页；canonical URL 优先。
- 同一附件多个入口以 content_hash 去重。
- 对登录、校园网、验证码页面标记 restricted，不绕过权限。

7. 网页采集、解析与清洗

7.1 抓取参数

参数	建议值	说明
并发	每域名 2-4	避免对学校服务器造成压力
间隔	0.5-1.5 秒随机	加抖动
超时	连接 10s / 读取 30s	PDF 可更长
重试	2-3 次指数退避	仅 429/5xx/网络错误
最大 HTML	5MB	超限人工检查
最大 PDF	50MB	超限按价值决定

7.2 原始留档与 Manifest

```
{
  "doc_id": "sha256:...",
  "url": "https://...",
  "local_path": "data/raw/html/...html",
  "mime_type": "text/html",
  "status_code": 200,
  "etag": "...",
  "last_modified": "...",
  "content_hash": "...",
  "crawl_time": "2026-06-11T...Z",
  "source_id": "osa_student_affairs"
}
```

7.3 HTML 解析顺序

11. 检测编码并保留原始标题、meta description、canonical URL。
12. 优先 trafilatura 提取主正文；提取失败时用 BeautifulSoup 站点规则。

13. 删除 nav/header/footer/sidebar/script/style/form，以及重复友情链接。
14. 保留标题层级、段落、列表、表格和可解释的超链接文本。
15. 识别发布日期、更新时间、部门、面包屑路径。
16. 标准化空白、标点和换行，保持课程编号、电话、年份原样。
17. 对文本过短、链接密度过高、乱码、软 404 页面拒绝入库。

7.4 质量阈值

检查	拒绝/告警条件
正文长度	少于 100 中文字符：默认拒绝；FAQ 可例外
链接比例	链接文本占比过高：可能为目录页
重复率	与已有正文相似度 >0.95：只保留权威/更新版本
乱码	不可见字符或替换符过多
导航污染	高频菜单词大量重复
时效	旧通知无年份或状态：仅历史库

8. PDF 与培养方案解析

8.1 PDF 分类与解析器选择

类型	识别	主解析器	处理
文本型	可复制文字	PyMuPDF	按页提取、页眉页脚去除
复杂表格/双栏	阅读顺序复杂	Docling	保留表格、标题、列表
扫描型	文字层为空	OCR 降级	仅核心资料使用；抽样校验
培养方案	固定章节+大量表格	专用 parser	同时产出原文、结构化行和问答友好文本

8.2 培养方案字段

- 专业、院系、年级、专业代码、学制、授予学位、最低毕业学分。
- 通识/专业基础/核心/实践/选修等模块学分。
- 进入专业时间、必修完成课程、替代规则和选拔说明。
- 课程编号、课程名、学分、建议学期、先修课程、开课单位。

8.3 三份输出

输出	用途	例子
原始块	引用与人工复核	保留原页码和表格文本
结构化记录	精确过滤/比较	major, course_code, credits, semester
检索文本	Dense/BM25	“2024 级机械工程 MA117 高等数学（上）4 学分...”

8.4 页码追踪

任何由 PDF 生成的 chunk 均保存 page_start/page_end。表格跨页时保存 source_boxes 或至少保存页范围，前端引用卡片显示“PDF 第 N 页”。

9. 统一数据模型、去重与版本管理

9.1 文档与 Chunk Schema

级别	关键字段
Document	doc_id, title, source_url, source_type, category, department, authority_level, published_date, effective_year, status, hash, local_path
Chunk	chunk_id, doc_id, parent_id, chunk_index, section_path, page_start/end, text, embedding_text, display_text, token_count, hash
Index Manifest	index_id, embedding_model, dimension, chunk_config, source_snapshot, doc_count, chunk_count, build_time

9.2 去重层级

18. URL 规范化去重。
19. 原始字节 content_hash 去重。
20. 清洗正文 hash 去重。
21. MinHash/SimHash 或 embedding 相似度检测近重复。
22. Chunk 重复：相同 doc 内导航/版权段删除；跨站转载保留权威源。

9.3 版本字段

```
doc_family_id: undergraduate_handbook
version: 2026
status: current | historical | superseded | unknown
effective_year: 2026
supersedes: doc_id_of_2025
is_current: true
```

9.4 冲突原则

- 用户指定年份：严格过滤 effective_year。
- 用户未指定年份：当前有效、中央职能部门、发布日期更近者优先。
- 若两个官方来源冲突且无法判定：回答中明确列出差异，不擅自合并。
- 历史文档不删除；只是不参与默认当前查询。

10. Chunking 与 Parent-Child 设计

10.1 默认参数

文档类型	切分规则	目标长度	Overlap
普通网页	H1/H2/H3 + 段落	300-600 中文字	50-80 字
规章制度	章/节/条；条款不拆	200-700 字	按语义，不机械重叠
培养方案	模块+表格行/小表	按语义单元	标题前缀
FAQ	一问一答	完整 QA	0
长指南	Child 检索 + Parent 回填	Child 250-450; Parent 800-1500	适度

10.2 embedding_text 构造

文档：机械工程专业本科人才培养方案

适用：2024 级

章节：三、学制、授予学位及毕业学分要求

正文：本专业毕业最低学分要求为 163 学分……

10.3 约束

- 不要把课程表一行拆开；不要把标题留在前块、正文放到后块。
- 过短块与相邻块合并，但不得跨越无关章节。
- 同一 parent 的 child 必须保持顺序和 parent_id。
- 建立 fixed-512 baseline，用于证明结构切分的贡献。

11. Embedding 与离线向量化

11.1 模型与实验

主候选为 Qwen3-Embedding-0.6B；BGE-M3 作为同数据、同 chunk、同指标对比。模型最终以开发集 Recall@5、MRR@10、延迟和资源占用决定。

11.2 批处理流程

23. 加载 chunks.jsonl，过滤 empty/duplicate/rejected。
24. 按 token 长度分桶，动态 batch，先小 batch 验证显存。
25. 使用 embedding_text，统一 normalize；记录模型 revision。
26. 每个 batch 写向量缓存和进度；支持中断续跑。
27. 完成后核对向量数、维度、NaN、L2 范数和 chunk_id 唯一性。

11.3 建议初始参数

参数	初始值	备注
max_length	1024-2048 tokens	中文校园 chunk 通常足够
batch_size	16 起步	以显存实测为准
normalize	True	使用 cosine/dot 一致

dtype	FP16/BF16	按模型支持
cache	按 model+chunk_hash	避免重算

12. Qdrant、BM25 与索引一致性

12.1 Qdrant Collection

```
collection: sustech_chunks_v1
vector_name: dense
size: <embedding_dimension>
distance: Cosine
payload_indexes:
  - category (keyword)
  - department (keyword)
  - effective_year (integer)
  - status (keyword)
  - doc_id (keyword)
  - source_type (keyword)
```

12.2 BM25 中文处理

- 中文分词使用可控 tokenizer；加入专业名、部门名、书院名词典。
- 课程代码（MA117、CS112）、年份、电话号码和英文缩写整体保留。
- 不要删除数字；停用词仅删除无检索价值的高频虚词。
- 保存 BM25 document list 与 chunk_id 列表，序列化时绑定 index_version。

12.3 一致性检查

28. chunks.jsonl 的 chunk_id 唯一。
29. Qdrant point id、BM25 row id、本地 chunk store 映射完全一致。
30. 任何一侧缺失都使索引构建失败，不允许静默跳过。
31. 索引切换使用新 collection + alias，避免在线服务读到半成品。

13. 混合检索、RRF 与 Reranker

13.1 默认检索参数

阶段	参数	初始值
Dense	top_k	30
BM25	top_k	30
RRF	k	60
融合	保留	30
Reranker	候选	30
最终上下文	Top-K	5（可调 3/5/8）

13.2 RRF

```
score(d) = sum(1 / (60 + rank_r(d)))
for r in [dense, bm25]
```

不要直接相加 dense score 与 BM25 score，因为量纲和分布不同。RRF 使用排名融合，首版更稳定、可解释。

13.3 Reranker

- 输入为 query + candidate chunk；只对 20-30 个候选运行。
- 批量推理，保留原 RRF 排名和 rerank score 便于调试。
- Reranker 的目标是提升 Top-1/MRR，不会增加第一阶段召回。
- 显存不足时将 reranker 放 CPU，或候选从 30 降到 15；不能因此取消完整 baseline。

13.4 后处理

- 同一 doc 高度重叠块合并；每文档最多 2-3 块。
- Top-2 可扩展相邻块或 parent，其他候选不扩展。
- 旧版本与当前版本冲突时，先按 query 年份过滤，再按 status/authority 处理。
- 所有选择动作写入 trace，便于判断错误来自哪一步。

14. Query 分析、多轮改写与比较题拆分

14.1 Query Analyzer 输出

```
{
  "original_query": "那信息工程呢？",
  "standalone_query": "2024 级信息工程专业最低毕业学分是多少？",
  "entities": ["信息工程"],
  "effective_year": 2024,
  "intent": "fact_lookup",
  "sub_queries": [],
  "filters": {"category": "curriculum", "effective_year": 2024}
}
```

14.2 多轮规则

- 仅保留最近 3-5 轮和轻量实体状态（current_major/current_topic/effective_year）。
- 改写后的问题用于检索；原始问题和必要历史用于生成。
- 改写不得添加用户未表达的条件；无法确定指代时询问澄清。

14.3 比较题 Query Decomposition

```
Query: 机械工程和金融数学哪个最低毕业学分更高?
Subquery A: 2024 级机械工程最低毕业学分
Subquery B: 2024 级金融数学最低毕业学分
```

Constraint: 两个实体均需至少一个高质量证据
If missing one side: 禁止强行比较, 报告缺失。

15. 上下文组装、证据充分性与拒答

15.1 Context Builder

[1]
标题: 机械工程专业本科人才培养方案 (2024 级)
章节: 学制、授予学位及毕业学分要求
适用年份: 2024
来源: <https://...>
内容:

[2]
...

15.2 Token 预算

组成	建议预算
系统规则	300-500 tokens
历史与用户问题	200-800
证据	3,000-5,000
输出	500-1,000
总上下文	8K 初始; 必要时 12K

15.3 证据状态

状态	条件	回答行为
supported	高分证据直接支持核心事实	正常回答并逐事实引用
partially_supported	只支持部分要求或一个比较对象	回答已知部分并说明缺失
insufficient_evidence	无直接证据、严重冲突或只命中背景	明确拒答, 不用模型常识补齐

16. 本地生成模型与 vLLM 部署

16.1 模型决策

用途	建议
正式模型	Qwen 8B 级 Instruct, 优先可靠的 4-bit AWQ/GPTQ 权重
轻量 baseline	0.8B-3B 级模型
云模型	仅可选评测上界, 不是系统依赖
默认模式	非长思考; 复杂比较可单独实验

16.2 vLLM 启动模板

```
python -m vllm.entrypoints.openai.api_server \
  --model /srv/sustech-rag/models/generator \
  --host 0.0.0.0 --port 8000 \
  --quantization awq \
  --dtype half \
  --max-model-len 8192 \
  --gpu-memory-utilization 0.82 \
  --served-model-name sustech-rag-llm
```

参数必须以实际模型和 vLLM 版本为准。首次启动从较低 gpu-memory-utilization 和 8K 上下文开始，先做健康检查，再逐步增加。

16.3 显存验证步骤

32. 只启动 vLLM，记录空闲与启动后显存。
33. 分别测试 1K、4K、8K 输入和 512 输出。
34. 启动 RAG 后端，加载 embedding CPU 版本。
35. 尝试 reranker GPU；若 OOM，转 CPU 或降低候选数。
36. 记录峰值、P50/P95 延迟与 tokens/s，写入 deployment_report.json。

17. Prompt、引用映射与输出协议

17.1 System Prompt 要点

- 只能依据提供的官方资料回答。
- 关键事实必须引用 [1][2]；模型不能生成真实 URL。
- 资料不足明确拒答；不同年份冲突要说明适用范围。
- 比较题先分别提取对象事实，再计算差异。
- 不得编造电话、日期、课程、学分或政策。

17.2 引用映射

37. 后端给 selected contexts 分配临时 source_id。
38. Prompt 只暴露 [1]、[2] 与证据文本。
39. 模型输出后解析所有编号；非法编号删除并记录 citation_error。
40. 后端映射真实标题、URL、页码、snippet；前端以来源卡片展示。

17.3 API 输出协议

```
{
  "answer": "... [1]",
  "evidence_status": "supported",
  "citations": [{
    "source_id": 1,
    "doc_id": "...",
```

```

    "title": "...",
    "url": "...",
    "page": 3,
    "snippet": "..."
  }],
  "trace_id": "...",
  "retrieval_mode": "hybrid_rerank"
}

```

18. FastAPI、Gradio 与服务接口

18.1 FastAPI 接口

接口	用途
POST /chat	完整 RAG，支持流式
POST /chat/no-rag	无检索 baseline
POST /retrieve	仅检索，返回各阶段排名
POST /evaluate	批量评测入口
GET /health	检查 Qdrant/BM25/模型
GET /documents/{doc_id}	查看文档和元数据
GET /sources	数据源统计
POST /admin/reindex	管理员触发索引；需保护

18.2 Gradio 页面

- 聊天区：流式答案、引用编号、错误提示。
- 证据区：标题、年份、部门、页码、原文、Dense/BM25/RRF/Rerank 分数。
- 实验开关：No RAG / Dense / BM25 / Hybrid / Hybrid+Rerank。
- 高级调试：standalone query、subqueries、filters、阶段延迟。
- 演示模式隐藏复杂参数，只保留检索模式与证据卡片。

19. 评测集构建与标注规范

19.1 数据划分

集合	数量	用途
开发集	10-15	调 chunk、Top-K、阈值；可反复查看
正式测试集	60	冻结后只做最终比较
演示题	8-12	从测试范围选稳定但不泄漏答案的案例

19.2 题型分布

类型	数量
单一事实	12
精确实体/课程代码	8

语义改写	8
条件规则	8
跨文档比较	8
校园服务	6
时间敏感	5
无答案/拒答	5

19.3 本 Schema

```
{
  "question_id": "q001",
  "question": "机械工程专业最低毕业学分是多少？",
  "type": "single_fact",
  "reference_answer": "2024 级机械工程为 163 学分。",
  "required_facts": ["2024 级", "163 学分"],
  "relevant_doc_ids": ["..."],
  "relevant_chunk_ids": ["..."],
  "answerable": true,
  "effective_year": 2024
}
```

20. 实验矩阵、公平比较与参数选择

20.1 主实验

ID	配置	目的
A	LLM only	无 RAG baseline
B	Dense	基础 RAG
C	BM25	精确匹配 baseline
D	Dense+BM25+RRF	混合检索贡献
E	Hybrid+Reranker	完整主系统
F	E + Query Decomposition	比较题增强

20.2 附加实验

- 固定 512 字 vs 结构感知 vs Parent-Child。
- Qwen3-Embedding-0.6B vs BGE-M3。
- 候选 K=10/20/30；最终 context K=3/5/8。
- Reranker 有/无；记录 MRR 改善和延迟代价。

20.3 公平条件

- 同一个生成模型、Prompt、temperature、max tokens、测试集和索引快照。
- 每次只改变一个目标变量。
- 开发集调参后冻结；测试集结果不得继续反向调参。
- 保存完整 config、随机种子、模型 revision 与 Git commit。

21. 指标、人工评测与 LLM Judge

21.1 检索指标

指标	意义
Document Hit@K	Top-K 是否包含正确原文档
Chunk Hit@K	是否命中包含答案的具体块
Recall@K	多证据题召回比例
MRR@10	第一个相关证据排名
nDCG@10（可选）	多级相关性排序质量

21.2 生成指标

指标	检查
Answer Correctness	关键事实是否正确
Completeness	是否覆盖问题要求
Faithfulness	结论是否由证据支持
Citation Validity	编号是否存在
Citation Correctness	来源是否支持句子
Citation Completeness	关键事实是否均引用
Refusal Accuracy	无答案题是否拒答
False Refusal	有答案时是否误拒

21.3 评分组合

- 规则：数字、年份、课程代码、枚举项。
- 人工：全部 60 题至少一轮，0/1/2 分，并标 faithfulness/citation。
- LLM Judge：辅助评估自然语言完整性；固定模型、temperature=0、隐藏系统名称。
- 规则与 Judge 冲突、拒答题、年份题、引用题必须人工复核。

22. 错误分析与调试路径

22.1 错误分类

代码	错误
E1	知识库缺失
E2	网页解析错误
E3	PDF/表格解析错误
E4	Chunk 边界错误
E5	Dense 未召回
E6	BM25 未召回
E7	RRF/去重错误
E8	Reranker 排序错误
E9	年份或版本冲突
E10	Query 改写/拆分错误
E11	LLM 计算或证据使用错误

22.2 调试顺序

1. 原始数据里是否存在答案？
2. 解析后 document 是否保留答案？
3. 正确 chunk 是否生成？
4. Dense/BM25 Top-30 是否出现？
5. RRF 是否保留？
6. Reranker 是否推低？
7. 上下文组装是否丢失/冲突？
8. Prompt 中是否清晰？
9. 模型是否错误理解或引用？

23. 日志、监控、测试与复现

23.1 请求日志

```
trace_id, timestamp, session_id
original_query, standalone_query, sub_queries, filters
index_version, model_versions, retrieval_mode
dense_results, bm25_results, rrf_results, rerank_results
selected_context_ids, prompt_tokens, output_tokens
stage_latencies, total_latency, evidence_status, errors
```

23.2 测试层级

层级	测试
单元	URL 规范化、日期解析、chunk、RRF、citation mapping、token budget
集成	网页/PDF -> chunk -> 索引 -> retrieve; vLLM; 完整 /chat
回归	固定问题命中固定证据；引用不失效；无答案仍拒答
负载	连续 20-50 请求、长上下文、服务重启、Qdrant 恢复

23.3 复现文件

- pyproject/requirements.lock; Docker Compose; 模型 revision; Git commit。
- source snapshot、raw manifest、chunk config、index manifest。
- 测试集版本、实验 config、原始结果 JSONL、汇总 CSV。

24. 从零实施步骤与命令顺序

24.1 阶段 0 - 环境

41. 确认 nvidia-smi、CUDA、磁盘与端口；建立 /srv/sustech-rag。

42. 创建 Python 3.11 环境；安装爬虫、解析、Qdrant client、FastAPI、Gradio、评测依赖。
43. 单独创建 vLLM 环境，避免与解析依赖冲突。
44. 启动 Qdrant，并运行健康检查。

24.2 阶段 1 - 小样本数据

45. 启用 2-3 个网站和 5 份培养方案；限制 max_pages。
46. 运行 crawl，查看 manifest；随机打开原始文件。
47. 运行 parse/normalize；抽查所有 PDF 和至少 20 个网页。
48. 生成 chunks；检查标题路径、年份、页码和表格行。

24.3 阶段 2 - 最小 Dense RAG

49. 生成 embedding，写入 Qdrant。
50. 实现 /retrieve dense-only；用 10 道问题检查 Top-5。
51. 启动 vLLM；实现 /chat 与 citation mapping。
52. 得到第一条“回答+真实来源+页码”。

24.4 阶段 3 - 完整检索与数据扩充

53. 建立 BM25、RRF、Reranker；保留每阶段 trace。
54. 加入年份过滤、同文档去重、parent expansion。
55. 逐批扩大到 200-300 网页和 20-40 PDF；每批运行质量报告。
56. 冻结正式索引版本。

24.5 阶段 4 - 评测与前端

57. 建立开发集，选择 chunk、embedding、Top-K 和阈值。
58. 冻结配置，运行 60 题 A-E 主实验。
59. 完成人工评分与错误分类。
60. 实现 Gradio 演示页、启动脚本和无网演练。

25. 里程碑、验收标准与时间计划

25.1 里程碑

里程碑	验收
M1 数据管线	20 网页+5 PDF；可追溯；解析抽检通过
M2 Dense RAG	正确 chunk 可命中；本地 LLM 带引用回答
M3 Hybrid+Rerank	代码题 BM25 有贡献；MRR 提升；延迟记录
M4 正式知识库	200-300 网页、20-40 PDF；版本冻结
M5 正式评测	60 题全跑；No-RAG 与主系统对比；错误标注
M6 演示交付	一键启动；离线可用；演示和恢复流程完成

25.2 建议两周紧凑计划

天	任务
1-2	环境、source registry、小样本抓取
3-4	HTML/PDF 解析、chunk、质量抽检
5	Dense index + 基础 RAG
6-7	BM25/RRF/Reranker
8	扩大数据、去重、版本
9	评测集和开发集调参
10-11	正式实验与人工复核
12	前端、日志、演示
13	报告/PPT/图表
14	全新环境复现与答辩彩排

26. 风险、降级与故障排查

26.1 风险表

风险	主方案	降级
网页正文提取失败	trafilatura	BeautifulSoup 站点规则；人工导入核心页
PDF 表格错序	Docling	PyMuPDF+专用规则；结构化手工校正少量核心 PDF
OCR 质量差	不使用扫描资料	仅核心页 OCR 并标低置信度
Qdrant 故障	Docker volume + health	FAISS 本地索引
vLLM 兼容	锁定版本和模型	Transformers 服务；更小模型
显存不足	8B 4-bit、8K	reranker CPU；降低 K；更小模型
Rerank 太慢	批处理 GPU	候选 15；CPU 小模型；演示时缓存
数据过多噪声	质量门槛	缩至核心站点
现场无网络	全部本地	提前缓存所有模型和页面
资料冲突	metadata/version	明确列出冲突并拒绝武断结论

26.2 OOM 排查顺序

61. 确认没有重复 vLLM/transformers 进程。
62. 降低 max_model_len；缩短 context；降低 gpu_memory_utilization。
63. Reranker 转 CPU；Embedding 固定 CPU。
64. 降低 rerank batch 和候选 K。
65. 最后才更换更小生成模型。

27. 答辩演示与最终交付清单

27.1 演示脚本

66. 展示数据统计、来源类别和索引版本。
67. 问一个本地模型容易凭常识答错的培养方案事实题，比较 No-RAG 与 RAG。
68. 问课程代码题，展示 BM25 的召回贡献。

69. 问跨专业比较题，展示 query decomposition 和两个来源。

70. 问过期/无答案题，展示年份处理和拒答。

71. 展示实验表、延迟、典型错误和一次改进过程。

27.2 最终交付物

交付物	要求
代码仓库	清晰目录、README、启动脚本、测试
环境	lock 文件、Docker Compose、vLLM 启动说明
数据	source registry、manifest、normalized/chunks；原始数据按许可保留
索引	Qdrant storage/重建脚本、BM25 索引、index manifest
评测	dev/test JSONL、raw outputs、scores、error labels
展示	Gradio、项目报告、PPT、演示问题清单
运维	日志、健康检查、备份恢复、故障降级

附录 A. 官方数据源种子清单

A.1 使用原则

下面是首版 source registry 的种子与类别。实际抓取约 200-300 个有效网页，不等于只抓下表 URL；每个 seed 将按 allow/exclude 规则发现子页面。网站结构会变化，运行前必须复核可访问性、robots.txt、栏目路径和最新版本。

来源	Seed URL	内容	目标	排除/备注
学校主站	https://www.sustech.edu.cn/	学校概况、院系、组织机构	20-40	排除新闻流
学院/专业入口	https://www.sustech.edu.cn/zh/college.html	学院、系、专业入口	10-20	用于发现院系站
本科招生	https://zs.sustech.edu.cn/	招生简章、FAQ、培养特色	20-35	保留适用年份
教学相关	https://tao.sustech.edu.cn/	学籍、选课、校历、培养	30-60	优先制度和通知
学生工作部	https://osa.sustech.edu.cn/	学生事务、心理、书院、办事	30-60	排除活动新闻
图书馆	https://lib.sustech.edu.cn/	开馆、借阅、预约、资源	20-40	数据库详情择优
研究生院	https://gs.sustech.edu.cn/	培养、学位、奖助、迎新	20-40	排除名单
国际合作	https://global.sustech.edu.cn/	交换、短期、国际学生	15-30	保留项目年份
公开镜像	https://mirrors.sustech.edu.cn/	培养方案、学生手册等 PDF	20-40 PDF	验证官方来源与版本
力学与航空航天	https://mae.sustech.edu.cn/	专业介绍、培养方案	5-10	不抓科研新闻
机械与能源工程	https://mee.sustech.edu.cn/	机械/能源专业	5-10	培养方案优先
商学院	https://business.sustech.edu.cn/	金融工程、工业工程等	5-10	专业材料
数学系	https://math.sustech.edu.cn/	数学、金融数学	5-10	本科页面
统计与数据科学	https://stat-ds.sustech.edu.cn/	统计学、数据科学	5-10	本科页面
物理系	https://phy.sustech.edu.cn/	物理、应用物理	5-10	本科页面
电子与电气工程	https://eee.sustech.edu.cn/	信息工程、电子类	5-10	本科页面
计算机系	https://cse.sustech.edu.cn/	计算机专业和培养	5-10	本科页面
材料科学与工程	https://mse.sustech.edu.cn/	材料专业	3-8	本科页面
生物医学工程	https://bme.sustech.edu.cn/	生医工专业	3-8	本科页面
环境学院	https://ese.sustech.edu.cn/	环境专业	3-8	本科页面
海洋科学与工程	https://ocean.sustech.edu.cn/	海洋专业	3-8	本科页面
地球与空间科学	https://ess.sustech.edu.cn/	地空专业	3-8	本科页面
化学系	https://chem.sustech.edu.cn/	化学专业	3-8	本科页面

生命科学学院	https://bio.sustech.edu.cn/	生物专业	3-8	本科页面
医学院	https://med.sustech.edu.cn/	医学教育信息	3-8	仅公开学生相关
人文社科中心	https://shss.sustech.edu.cn/	通识、人文课程相关	3-8	择优
语言中心	https://cle.sustech.edu.cn/	外语培养与服务	3-8	择优
体育中心	https://sports.sustech.edu.cn/	体育教学、场馆服务	3-8	排除赛事新闻
信息化服务	主站/部门公开入口待确认	网络、邮箱、统一认证	8-15	校园网受限页不绕过
校医院/健康	主站/学生事务公开入口待确认	就诊、体检、健康服务	8-15	医疗回答只引用
六大书院	OSA 下各书院栏目	简介、位置、支持、设施	20-30	不抓活动流

A.2 优先补充的公开 PDF

- 2024 级本科人才培养方案：先覆盖 10-15 个专业，再根据时间扩展。
- 最新本科生手册、通识培养方案、学籍管理规定、学位授予办法。
- 最新本科与研究生招生简章、奖助学金制度、校园生活/新生指南。
- 历史版本仅在可明确标注年份和状态时保留。

附录 B. 配置模板与数据 Schema

B.1 建议配置文件

```
configs/
sources.yaml      # 数据源与抓取范围
parsing.yaml      # 站点规则、正文 selector、PDF parser
chunking.yaml     # 各文档类型切分规则
models.yaml       # model id/revision/device/max length
retrieval.yaml    # Top-K、RRF、rerank、filters
generation.yaml   # prompt、temperature、max tokens
evaluation.yaml    # test set、metrics、judge
logging.yaml      # level、rotation、PII policy
```

B.2 推荐仓库结构

```
sustech-rag/
configs/
data/{raw,parsed,normalized,chunks,manifests,eval}/
src/
  ingestion/ parsing/ normalization/ chunking/
  indexing/ retrieval/ reranking/ generation/
  evaluation/ api/ common/
frontend/
scripts/
tests/{unit,integration,regression}/
docker/
docs/
pyproject.toml
docker-compose.yml
README.md
```

B.3 最小 Makefile/任务命名

```
make env-check
make crawl SOURCE=core
make parse
make normalize
make chunk
make embed
make index
make serve-qdrant
make serve-llm
make serve-api
make serve-ui
make eval-dev
make eval-test
make test
make backup
```

附录 C. 参考资料

C.1 课程与项目材料

- Large Model Course Project Description: Project 1 要求完成公开校园数据、清洗切分、向量库、本地模型、RAG、No-RAG 对比、报告与现场演示。
- LAB 11: 标准流程为 Indexing -> Retrieval -> Generation; 强调 Hybrid Search、RRF、Reranking 和检索指标。
- Lec11: RAG 的 datastore、retriever、generator、稀疏/稠密检索与评测。

C.2 工业实现与官方文档

[R1] Qdrant Hybrid Queries: <https://qdrant.tech/documentation/search/hybrid-queries/> - Dense/Sparse prefetch 与 RRF 融合。

[R2] vLLM Online Serving: https://docs.vllm.ai/en/latest/serving/online_serving/ - OpenAI-compatible 服务。

[R3] vLLM OpenAI-Compatible Server: https://docs.vllm.ai/en/latest/serving/online_serving/openai_compatible_server/ - Chat/Completions API。

[R4] Qdrant 官网: <https://qdrant.tech/> - 向量数据库与检索服务。

[R5] 南方科技大学官网: <https://www.sustech.edu.cn/> - 校园官方数据主入口。

[R6] 南科大公开镜像: <https://mirrors.sustech.edu.cn/> - 公开培养方案和手册 PDF。

C.3 前已的公材料示例

- 2024 级统计学专业本科人才培养方案（南科大公开镜像）。

- 2024 级机械工程、航空航天工程等培养方案。
- 本科学生手册历史版本，用于验证版本与历史状态处理；不默认视为当前政策。
- 商学院公开的 2024 级金融工程、工业工程培养方案。

--- 文档结束 ---